CIÊNCIA DE DADOS EM SAÚDE • ATIVIDADE EM DUPLA

N1 – 2º Bimestre – Entrega 02

Implementação Analítica no Google Colab: Análise de Dados, Suporte à Tomada de Decisão Clínica e Avaliação Crítica e Ética para Doenças de Diagnóstico Complexo

1. Visão Geral e Objetivo da Etapa 02

Dando continuidade ao planejamento e mapeamento realizados na **Entrega 01** (onde a dupla selecionou uma patologia rara ou de diagnóstico complexo — como Doença de Creutzfeldt-Jakob, Esclerose Múltipla, Neuromielite Óptica, Huntington, Neurocisticercose Atípica, Lúpus Eritematoso Sistêmico, Doença Celíaca, Síndrome de Sjögren, Artrite Psoriásica sem Psoríase, Fibromialgia, Febre Familiar do Mediterrâneo, Síndrome da Fadiga Crônica ou Doença de Lyme — e realizou a curadoria do dataset em repositórios como Kaggle, PhysioNet, UCI, TCGA ou MIMIC), a Entrega 02 consiste na execução prática da pipeline analítica em Python.

O objetivo central desta etapa é construir um Notebook estruturado no Google Colab que transforme os dados brutos da patologia escolhida em evidências quantitativas e visuais acionáveis. A dupla deverá aplicar técnicas de pré-processamento, análise exploratória avançada e modelagem de dados para responder às 4 Perguntas Norteadoras definidas na Etapa 01, traduzindo métricas estatísticas e gráficos em interpretações clínicas para a tomada de decisão (Sistema de Suporte à Decisão Clínica – CDSS), acompanhadas de uma análise crítica e ética profunda e contextualizada nas especificidades da doença investigada.

- Modalidade: Trabalho realizado na mesma dupla da Entrega 01.
- Foco Analítico: Pré-processamento clínico, extração de métricas estatísticas e de desempenho, visualização de dados biomédicos, interpretação para tomada de decisão médica e governança ética em IA na saúde.
- Entregável Principal: Notebook executável no Google Colab (.ipynb e link compartilhado com permissão de visualização/execução) contendo código documentado, saídas visuais (gráficos e tabelas), análises interpretativas em células de texto (Markdown) e seção de discussão crítica e ética.

2. Enunciado da Atividade (Para os Alunos)

Contexto do Desafio:
Vocês atuam como cientistas de dados integrados a uma equipe médica multidisciplinar

especializada em doenças raras e de diagnóstico complexo. Na primeira etapa do projeto, vocês mapearam a fisiopatologia, os biomarcadores e os gargalos diagnósticos da condição escolhida, além de selecionar uma base de dados real e formular quatro questões fundamentais (Agrupamento, Classificação, Predição/Séries Temporais e Suporte Prescritivo à Decisão).Agora, na Entrega 02, sua missão é desenvolver o ambiente analítico completo no Google Colab. Mais do que executar algoritmos ou plotar figuras, um cientista de dados em saúde precisa garantir que cada métrica calculada e cada gráfico gerado responda a uma dúvida clínica real, orientando a conduta médica com segurança. Além disso, como doenças de difícil detecção envolvem forte assimetria de classes, ruídos de coleta hospitalar e alto impacto humano em caso de erro diagnóstico, vocês deverão avaliar criticamente as limitações técnicas da sua solução e discutir os dilemas éticos, riscos de viés e impactos na vida do paciente.

3. Estrutura Obrigatória do Notebook no Google Colab

O notebook deve ser organizado de forma sequencial, intercalando células de texto (Markdown) — para contextualização, justificativas metodológicas e interpretação de resultados — e células de código (Python) devidamente comentadas e executadas (todas as saídas devem estar visíveis no momento da entrega).

Seção 01: Identificação, Resgate Clínico e Carregamento da Base

1. Cabeçalho do Projeto: Nome dos integrantes da dupla (Person e Person), título do projeto, patologia selecionada e link direto para a fonte original do dataset (Kaggle, PhysioNet, UCI, TCGA, MIMIC, etc.).
2. Síntese do Problema Clínico: Breve resumo (1 a 2 parágrafos) relembrando a fisiopatologia, os principais biomarcadores analisados e as 4 perguntas de Ciência de Dados propostas na Entrega 01.
3. Ingestão e Inspeção Inicial: Carregamento reprodutível dos dados (pandas, numpy), exibição das dimensões da base (shape), tipos de variáveis (info()) e amostra dos registros (head()).

Seção 02: Tratamento da Qualidade dos Dados e Pré-processamento Clínico

Implementação prática do checklist mapeado na Entrega 01, justificando cada decisão sob a ótica médica (por que remover ou imputar um dado clínico pode alterar o desfecho diagnóstico):

1. **Tratamento de Dados Faltantes (Missing Values):** Quantificação exata (% por atributo) e aplicação de estratégia de imputação (média/mediana estratificada por grupo clínico, KNN Imputer ou descarte justificado), explicando se a ausência do exame no prontuário é aleatória ou informativa (ex.: exame invasivo solicitado apenas em casos graves).
2. **Análise e Manejo de Outliers e Ruídos:** Identificação de valores biologicamente implausíveis (erro de coleta/digitação hospitalar) versus valores extremos patológicos reais (crises agudas ou surtos inflamatórios que **não** devem ser excluídos sem critério clínico).

3. **Análise de Desbalanceamento de Classes:** Quantificação da proporção real entre pacientes positivos (ou subtipos da doença rara) e controles saudáveis/outras patologias, discutindo estratégias de mitigação (ponderação de classes, *undersampling*, *oversampling*/SMOTE ou ajuste de limiar de decisão).
4. **Padronização e Codificação:** Normalização/escalonamento de biomarcadores contínuos (`StandardScaler`, `MinMaxScaler` ou `RobustScaler`) e codificação de variáveis categóricas clínicas.

Seção 03: Métricas Estatísticas e Análise Exploratória e Modelagem (Respondendo às Perguntas da Entrega 01)

Desenvolvimento das análises quantitativas e modelos voltados às perguntas formuladas na Etapa 01. O notebook deve apresentar e interpretar dois blocos de métricas:

A. Métricas Estatísticas Descritivas e Inferenciais (Biomarcadores e Perfil Clínico)

- **Tendência Central e Dispersão por Grupo (Doentes vs. Controles / Subgrupos):** Média, desvio-padrão, mediana e intervalo interquartil (IIQ) — essenciais devido à frequente assimetria (*skewness*) de marcadores inflamatórios, genéticos ou laboratoriais.
- **Associação e Correlação:** Coeficientes de correlação de Pearson ou Spearman entre biomarcadores contínuos, e tabelas de contingência / teste Qui-quadrado ou testes de hipótese (Teste *t* de Student ou Mann-Whitney) para verificar quais biomarcadores apresentam diferença estatisticamente significativa entre os desfechos.

B. Métricas de Desempenho Analítico / Modelagem (Conforme o Escopo das Perguntas)

A dupla deve implementar pelo menos duas abordagens analíticas alinhadas às perguntas de Descoberta (Agrupamento), Diagnóstico Diferencial (Classificação) ou Evolução (Regressão/Séries Temporais), calculando obrigatoriamente as métricas abaixo:

Eixo Analítico	Métricas Obrigatórias no Colab	Significado Clínico Obrigatório na Interpretação
Diagnóstico Diferencial (Classificação Supervisionada)	• Matriz de Confusão Completa• **Sensibilidade (Recall)**• **Especificidade**• **Precisão (Valor Preditivo Positivo)** e Valor Preditivo Negativo (VPN)• **F1-Score** e **AUC-ROC / AUC-PR**	Avaliar o custo clínico dos **Falsos Negativos** (paciente com doença rara sem tratamento precoce) versus **Falsos Positivos** (submeter paciente a biópsias invasivas, imunossupressores ou estigma psicológico). Explicar por que a *Acurácia Global* isolada é enganosa em bases desbalanceadas.
Descoberta de Fenótipos (Agrupamento / Clustering)	• **Coeficiente de Silhueta (Silhouette Score)** ou Índice	Verificar se os agrupamentos matemáticos correspondem a

Eixo Analítico	Métricas Obrigatórias no Colab	Significado Clínico Obrigatório na Interpretação
	Davies-Bouldin• Inércia / Variância Explicada (PCA/t-SNE)• Perfil estatístico médio de cada cluster	fenótipos clínicos reais (ex.: estágio inicial vs. avançado, forma remitente-recorrente vs. progressiva, perfil de baixo vs. alto risco).
Predição Contínua / Evolução Temporal (Regressão / Séries)	• **MAE** (Erro Médio Absoluto)• **RMSE** (Raiz do Erro Quadrático Médio)• **R^2** (Coeficiente de Determinação)	Traduzir o erro numérico na unidade real do biomarcador ou escala clínica (ex.: errar em X pontos na escala funcional altera a conduta médica?).

4. Repertório de Visualizações e Gráficos Obrigatórios

Todos os gráficos devem ser gerados em Python (`matplotlib`, `seaborn` ou `plotly`) diretamente no Google Colab, contendo título informativo, rótulos nos eixos com unidades de medida clínicas, legenda clara e paleta de cores acessível. Abaixo de cada gráfico, é obrigatória uma célula Markdown com a leitura técnica e clínica da figura:

1. **Gráfico de Qualidade e Proporção da Base:**
    - Gráfico de barras ou matriz visual de valores ausentes por atributo antes do tratamento, **e** gráfico de proporção de classes (evidenciando o grau de raridade/desbalanceamento da patologia).
2. **Distribuição Comparativa de Biomarcadores-Chave (Boxplots ou Violin Plots):**
    - Comparação direta da distribuição dos principais indicadores clínicos/genéticos/laboratoriais entre pacientes positivos e grupo controle (ou entre subtipos da doença), destacando medianas, dispersão e *outliers* patológicos.
3. **Mapa de Calor de Correlação (Correlation Heatmap) ou Pairplot:**
    - Visualização das interações multivariadas entre sintomas, exames laboratoriais e variáveis demográficas para identificar redundâncias ou sinergias diagnósticas.
4. **Visualização de Padrões Latentes ou Séries Temporais (Projeção 2D / Curvas de Evolução):**
    - Gráfico de dispersão (*Scatter Plot*) com redução de dimensionalidade (PCA, t-SNE ou UMAP) colorindo os clusters/fenótipos encontrados **ou** curvas temporais de evolução dos sinais vitais/biomarcadores dos pacientes.
5. **Painel Visual de Avaliação de Desempenho e Decisão:**
    - Plotagem da **Matriz de Confusão** acompanhada da **Curva ROC (ou Curva Precision-Recall)** e do **Gráfico de Importância de Variáveis (Feature Importance / SHAP)**, demonstrando visualmente quais biomarcadores mais pesam na decisão do algoritmo.

5. Interpretação dos Dados para a Tomada de Decisão Clínica (CDSS)

Esta seção do notebook conecta os resultados estatísticos à **Pergunta 04 da Entrega 01 (Aplicação Prescritiva e Suporte à Decisão)**. A dupla deve redigir uma análise estruturada respondendo aos seguintes pontos:

1. **Hierarquia de Biomarcadores e Triagem:** Com base nos gráficos de distribuição e na importância das variáveis, quais são os 3 a 5 indicadores mais determinantes para suspeitar precocemente da doença? Como isso pode otimizar a solicitação de exames caros ou invasivos no hospital?
2. **Definição de Limiares de Risco (Threshold Tuning):** Em vez de usar o corte padrão de 50% de probabilidade do modelo, qual ponto de corte a dupla recomenda para um Sistema de Suporte à Decisão Clínica (CDSS)?
    - *Exemplo prático:* Priorizar alta sensibilidade na triagem primária (para não deixar nenhum paciente com doença neurodegenerativa ou autoimune passar despercebido) e exigir alta especificidade na confirmação diagnóstica.
3. **Fluxo Prescritivo de Conduta:** Como o médico utilizará o resultado dessa análise no consultório ou UTI? Descreva uma recomendação prática (ex.: *"Pacientes alocados no Cluster B com elevação simultânea dos marcadores X e Y devem ser encaminhados prioritariamente para ressonância magnética / painel genético e monitoramento quinzenal"*).

6. Análise Crítica e Ética Contextualizada no Problema

Em Ciência de Dados em Saúde, decisões algorítmicas impactam diretamente a qualidade de vida e a sobrevida humana. O notebook deve conter uma seção dedicada exclusivamente à reflexão crítica, ética e regulatória, contextualizada na patologia escolhida pela dupla (textos genéricos sobre IA não serão aceitos; a discussão deve citar os exames, sintomas e grupos demográficos da doença estudada):

1. **Vieses de Dados e Representatividade Epidemiológica (Algorithmic Bias):**
    - O dataset utilizado representa a diversidade populacional real ou foi coletado em um único centro hospitalar/país?
    - Como recortes demográficos (sexo biológico, faixa etária, etnia ou nível socioeconômico) afetam a prevalência e a manifestação da doença escolhida? (Ex.: doenças autoimunes como Lúpus e Sjögren têm forte predominância feminina; certas condições genéticas ou infecciosas têm distribuição geográfica específica). Se o modelo for aplicado no sistema de saúde brasileiro (SUS/saúde suplementar), que distorções podem ocorrer?
2. **Impacto Ético dos Erros Diagnósticos (Falsos Positivos vs. Falsos Negativos):**
    - **Consequências de um Falso Negativo na patologia estudada:** Atraso no início de terapias modificadoras da doença, progressão irreversível de sequelas neurológicas/sistêmicas ou risco de óbito.

    - **Consequências de um Falso Positivo na patologia estudada:** Ansiedade grave diante de um diagnóstico sombrio (como DCJ ou Huntington), realização desnecessária de procedimentos invasivos (punção lombar, biópsia) e efeitos colaterais severos de medicamentos imunossupressores ou corticoides em pacientes que não possuem a doença.
3. **Explicabilidade (XAI), Caixa-Preta e Autonomia Médica:**
    - Por que médicos e pacientes não devem confiar cegamente em um alerta automatizado? Como garantir que a ferramenta funcione como **suporte** (segunda opinião baseada em dados) e nunca como substituta do julgamento clínico e da anamnese humanizada?
4. **Privacidade, Dados Sensíveis e Conformidade com a LGPD:**
    - Dados genéticos, prontuários eletrônicos e exames de doenças raras são **dados pessoais sensíveis** (Art. 5º, II da LGPD). Em doenças raras, o baixo número de casos facilita a **reidentificação indireta** do paciente mesmo após a remoção do nome (pseudoanonimização). Quais cuidados éticos e de governança são indispensables ao compartilhar e modelar essas bases?

7. Checklist de Entregáveis e Rubrica de Avaliação

Checklist Final para Submissão

- ☐ Link do **Google Colab** configurado com permissão de leitura/visualização aberta ao professor e arquivo `.ipynb` exportado.
- ☐ Todas as células de código executadas sem erros de sintaxe e com saídas (tabelas e gráficos) visíveis.
- ☐ Dicionário resumido e tratamento documentado de *missing values*, *outliers* e desbalanceamento.
- ☐ Pelo menos **5 visualizações gráficas** com padrão profissional e interpretação textual logo abaixo de cada figura.
- ☐ Cálculo e interpretação clínica das métricas estatísticas e de modelagem (Sensibilidade, Especificidade, F1/AUC, Silhueta ou MAE/RMSE).
- ☐ Seção de Suporte à Tomada de Decisão Clínica (CDSS) respondendo às questões da Entrega 01.
- ☐ Seção de Análise Crítica e Ética contextualizada especificamente na patologia da dupla.

Matriz de Avaliação (10,0 Pontos)

Critério de Avaliação	Peso	Descrição do que será avaliado
1. Organização, Reprodutibilidade e Pré-processamento no Colab	**2,0 pts**	Estrutura limpa do notebook, código comentado, justificativa clínica para limpeza de ruídos, imputação de dados faltantes e tratamento do desbalanceamento.

Critério de Avaliação	Peso	Descrição do que será avaliado
2. Rigor nas Métricas Estatísticas e Modelagem Analítica	**2,5 pts**	Escolha adequada das métricas descritivas e de avaliação (Sensibilidade, Especificidade, AUC, Silhueta, etc.) em consonância com as perguntas da Entrega 01.
3. Qualidade Técnica e Visual dos Gráficos	**2,0 pts**	Clareza visual, escolha correta do tipo de gráfico para cada variável biomédica, presença de títulos/unidades e leitura analítica de cada figura.
4. Interpretação Clínica para Tomada de Decisão (CDSS)	**2,0 pts**	Capacidade de traduzir números e gráficos em recomendações práticas de triagem, diagnóstico diferencial, ajuste de limiar e conduta médica.
5. Profundidade da Análise Crítica e Ética Contextualizada	**1,5 pts**	Discussão fundamentada na patologia específica sobre vieses populacionais, impacto humano de falsos positivos/negativos, explicabilidade e privacidade (LGPD).
Total	**10,0 pts**	**Nota da Entrega 02 (N1 – 2º Bimestre)**